

Análisis estadístico del Estudio de Desempleo

- Autor: Juan Ernesto Díaz Noguez

Resumen

Este reporte describe los resultados obtenidos del análisis estadístico del Estudio del desempleo, el cual forma parte del Reto. La muestra es de 50 personas desempleadas en la industria manufacturera a las cuales se recolectaron variables cuantitativas como: semanas de dempleo, edad, educación y años en el trabajo anterior. De igual manera se recolectaron variables cualitativas como estado civil (si la persona está soltera o casada), si es o no cabeza de familia, si contaba o no con un puesto de relacioando a la administración y si su ocupación es en ventas.

El analisis permitió identificar las principales características de los datos, su variabilidad, distribución y presencia de valores atípicos.

Introducción

El objetivo del análisis es describir las características de la muestra de personas desempleadas mediante el uso de diferentes medidas estadísticas. Para ello, se analizaron las medidas de tendencia central, variabilidad y forma de las variables cuantitativas, tomando en consideración la normalidad y presencia de valores atípicos. Para las variables cualitativas se analizaron la moda y sus frecuencias.

Importación de librerías y datos

```
In [10]: #! pip install statsmodels
```

```
In [11]: import pandas as pd
import numpy as np
from statsmodels.stats.diagnostic import normal_ad
```

```
In [12]: df = pd.read_csv("./CasoDesempleoDatosOriginales.csv")
df
```

Out[12]:

	Persona	Semanas	Edad	Educación	Casado	Cabeza Fam	Años Trab Ant	Administrador	Ver
0	1	37	30	14	Casado	Cabeza familia	1	No Administrador	
1	2	62	27	14	Casado	no cabeza familia	6	No Administrador	Ver
2	3	49	32	10	Soltero	Cabeza familia	11	No Administrador	Ver
3	4	73	44	11	Casado	no cabeza familia	2	No Administrador	Ver
4	5	8	21	14	Casado	Cabeza familia	2	No Administrador	Ver
5	6	15	26	13	Casado	no cabeza familia	7	Administrador	Ver
6	7	52	26	15	Casado	no cabeza familia	6	No Administrador	Ver
7	8	72	33	13	Soltero	Cabeza familia	6	No Administrador	Ver
8	9	11	27	12	Casado	Cabeza familia	8	No Administrador	Ver
9	10	13	33	12	Soltero	Cabeza familia	2	No Administrador	Ver
10	11	39	20	11	Casado	no cabeza familia	1	No Administrador	Ver
11	12	59	35	7	Casado	Cabeza familia	6	No Administrador	Ver
12	13	39	36	17	Soltero	Cabeza familia	9	Administrador	Ver
13	14	44	26	12	Casado	Cabeza familia	8	No Administrador	Ver
14	15	56	36	15	Soltero	Cabeza familia	8	No Administrador	Ver
15	16	31	38	16	Casado	Cabeza familia	11	No Administrador	Ver
16	17	62	34	13	Soltero	Cabeza familia	13	No Administrador	Ver
17	18	25	27	19	Casado	no cabeza	8	No Administrador	Ver

	Persona	Semanas	Edad	Educación	Casado	Cabeza Fam	Años Trab Ant	Administrador	Ven
						familia			
18	19	72	44	13	Casado	no cabeza familia	22	No Administrador	Ver
19	20	65	45	15	Casado	Cabeza familia	6	No Administrador	Ver
20	21	44	28	17	Soltero	Cabeza familia	3	No Administrador	Ver
21	22	49	25	10	Casado	Cabeza familia	1	No Administrador	Ver
22	23	80	31	15	Casado	no cabeza familia	12	No Administrador	Ver
23	24	7	23	15	Casado	no cabeza familia	2	No Administrador	Ver
24	25	14	24	13	Casado	Cabeza familia	7	No Administrador	Ver
25	26	94	62	13	Soltero	Cabeza familia	8	No Administrador	Ver
26	27	48	31	16	Casado	no cabeza familia	11	No Administrador	Ver
27	28	82	48	18	Soltero	Cabeza familia	30	No Administrador	Ver
28	29	50	35	18	Casado	Cabeza familia	5	No Administrador	Ver
29	30	37	33	14	Soltero	Cabeza familia	6	No Administrador	Ver
30	31	62	46	15	Soltero	Cabeza familia	6	No Administrador	Ver
31	32	37	35	8	Soltero	Cabeza familia	6	No Administrador	Ver
32	33	40	32	9	Casado	Cabeza familia	13	No Administrador	Ver
33	34	16	40	17	Casado	no cabeza familia	8	Administrador	Ver
34	35	34	23	12	Casado	Cabeza familia	1	No Administrador	Ver

	Persona	Semanas	Edad	Educación	Casado	Cabeza Fam	Años Trab Ant	Administrador	Ver
35	36	4	36	16	Soltero	Cabeza familia	8	No Administrador	Ver
36	37	55	33	12	Casado	no cabeza familia	10	No Administrador	Ver
37	38	39	32	16	Soltero	Cabeza familia	11	No Administrador	Ver
38	39	80	62	15	Casado	no cabeza familia	16	No Administrador	Ver
39	40	19	29	14	Casado	Cabeza familia	12	No Administrador	Ver
40	41	98	45	12	Casado	no cabeza familia	17	No Administrador	Ver
41	42	30	38	15	Soltero	Cabeza familia	6	No Administrador	Ver
42	43	22	40	8	Casado	Cabeza familia	16	No Administrador	Ver
43	44	57	42	13	Casado	no cabeza familia	2	Administrador	Ver
44	45	64	45	16	Casado	Cabeza familia	22	No Administrador	Ver
45	46	22	39	11	Casado	Cabeza familia	4	No Administrador	Ver
46	47	27	27	15	Casado	no cabeza familia	10	No Administrador	Ver
47	48	20	42	14	Casado	Cabeza familia	6	Administrador	Ver
48	49	30	31	10	Casado	Cabeza familia	8	No Administrador	Ver
49	50	23	33	13	Casado	Cabeza familia	8	No Administrador	Ver

Limpieza y estandarización de datos

```
In [13]: display(df["Casado"].value_counts())
```

```
Casado
Casado      35
Soltero     15
Name: count, dtype: int64
```

```
In [14]: df["Casado"] = df["Casado"].map({
        "Casado": True,
        "Soltero": False
    })
```

```
In [15]: display(df["Casado"].value_counts())
```

```
Casado
True      35
False     15
Name: count, dtype: int64
```

```
In [16]: display(df["Cabeza Fam"].value_counts())
```

```
Cabeza Fam
Cabeza familia      34
no cabeza familia   16
Name: count, dtype: int64
```

```
In [17]: df["Cabeza Fam"] = df["Cabeza Fam"].map({
        "Cabeza familia": True,
        "no cabeza familia": False
    })
```

```
In [18]: display(df["Cabeza Fam"].value_counts())
```

```
Cabeza Fam
True      34
False     16
Name: count, dtype: int64
```

```
In [19]: display(df["Administrador"].value_counts())
```

```
Administrador
No Administrador    45
Administrador       5
Name: count, dtype: int64
```

```
In [20]: df["Administrador"] = df["Administrador"].map({
        "Administrador": True,
        "No Administrador": False
    })
```

```
In [21]: display(df["Administrador"].value_counts())
```

```
Administrador
False     45
True       5
Name: count, dtype: int64
```

```
In [22]: display(df["Ventas"].value_counts())
```

```
Ventas
No Ventas    40
Ventas       9
0            1
Name: count, dtype: int64
```

```
In [23]: df["Ventas"] = df["Ventas"].map({
    "Ventas": True,
    "No Ventas": False,
    "1": True,
    "0": False
})
```

```
In [24]: display(df["Ventas"].value_counts())
```

```
Ventas
False    41
True      9
Name: count, dtype: int64
```

```
In [25]: df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 50 entries, 0 to 49
Data columns (total 9 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Persona               50 non-null    int64
1   Semanas               50 non-null    int64
2   Edad                 50 non-null    int64
3   Educación             50 non-null    int64
4   Casado                50 non-null    bool
5   Cabeza Fam           50 non-null    bool
6   Años Trab Ant         50 non-null    int64
7   Administrador         50 non-null    bool
8   Ventas                50 non-null    bool
dtypes: bool(4), int64(5)
memory usage: 2.3 KB
```

```
In [26]: df.set_index("Persona", inplace=True)
print(df.columns.to_list())
```

```
['Semanas', 'Edad', 'Educación', 'Casado', 'Cabeza Fam', 'Años Trab Ant', 'Administrador', 'Ventas']
```

Método

Se realizó un análisis estadístico descriptivo sobre una muestra de 50 observaciones. Para las variables cuantitativas se calcularon la media, mediana, moda, desviación estándar, rango intercuartílico y sesgo. También se utilizaron histogramas y diagramas de caja para observar la forma de las distribuciones y detectar valores atípicos. La normalidad fue evaluada mediante la prueba de Anderson-Darling, utilizando un nivel de significancia de $\alpha = 0.05$. Para las variables consideradas normales en la práctica se utilizó la regla empírica, mientras que para aquellas que no presentaron una distribución

normal se utilizó la desigualdad de Chebyshev. Para las variables cualitativas se calcularon la moda y las frecuencias absoluta, relativa y porcentual, además de representar su distribución mediante gráficas de barras.

Selección de variables cuantitativas y cualitativas

Variables involucradas

Las variables cuantitativas analizadas fueron semanas de desempleo, edad, educación y años de trabajo anterior. Las variables cualitativas fueron casado, cabeza de familia, administrador y ventas. La variable persona funciona únicamente como identificador de cada observación y no fue considerada como una característica para el análisis estadístico.

```
In [27]: cuantitativas = [  
          "Semanas",  
          "Edad",  
          "Educación",  
          "Años Trab Ant"  
        ]  
  
        cualitativas = [  
          "Casado",  
          "Cabeza Fam",  
          "Administrador",  
          "Ventas"  
        ]
```

Presentación de medidas resumen

```
In [28]: display(df[quantitativas].describe())
```

	Semanas	Edad	Educación	Años Trab Ant
count	50.000000	50.000000	50.000000	50.000000
mean	43.360000	34.600000	13.520000	8.360000
std	23.680492	9.059891	2.689663	5.844097
min	4.000000	20.000000	7.000000	1.000000
25%	23.500000	27.250000	12.000000	6.000000
50%	39.500000	33.000000	14.000000	8.000000
75%	61.250000	39.750000	15.000000	11.000000
max	98.000000	62.000000	19.000000	30.000000

Cálculo de las demás medidas resumen y variables necesarias

```
In [29]: resumen_cuantitativas = pd.DataFrame({
    "Media": df[cuantitativas].mean(),
    "Mediana": df[cuantitativas].median(),
    "Moda": df[cuantitativas].mode().iloc[0],
    "Desviación estándar": df[cuantitativas].std(),
    "Varianza": df[cuantitativas].var(),
    "Mínimo": df[cuantitativas].min(),
    "Q1": df[cuantitativas].quantile(0.25),
    "Q3": df[cuantitativas].quantile(0.75),
    "Máximo": df[cuantitativas].max(),
    "Sesgo": df[cuantitativas].skew()
})

resumen_cuantitativas
```

```
Out[29]:
```

	Media	Mediana	Moda	Desviación estándar	Varianza	Mínimo	Q1	Q3	Má
Semanas	43.36	39.5	37.0	23.680492	560.765714	4	23.50	61.25	
Edad	34.60	33.0	33.0	9.059891	82.081633	20	27.25	39.75	
Educación	13.52	14.0	15.0	2.689663	7.234286	7	12.00	15.00	
Años Trab Ant	8.36	8.0	6.0	5.844097	34.153469	1	6.00	11.00	

```
In [30]: resumen_cuantitativas["Rango"] = (resumen_cuantitativas["Máximo"] - resumen_cuantitativas["Mínimo"])
resumen_cuantitativas["RIQ"] = (resumen_cuantitativas["Q3"] - resumen_cuantitativas["Q1"])
resumen_cuantitativas["Coeficiente de variación"] = (resumen_cuantitativas["Desviación estándar"] / resumen_cuantitativas["Media"])
```

```
In [31]: resumen_cuantitativas["Límite inferior (2 Desviación estándar)"] = (resumen_
resumen_cuantitativas["Límite superior (2 Desviación estándar)"] = (resumen_
```

```
In [32]: resumen_cuantitativas = resumen_cuantitativas.round(2)
```

```
In [33]: resumen_cuantitativas
```

Out[33]:

	Media	Mediana	Moda	Desviación estándar	Varianza	Mínimo	Q1	Q3	Máxim
Semanas	43.36	39.5	37.0	23.68	560.77	4	23.50	61.25	
Edad	34.60	33.0	33.0	9.06	82.08	20	27.25	39.75	
Educación	13.52	14.0	15.0	2.69	7.23	7	12.00	15.00	
Años Trab Ant	8.36	8.0	6.0	5.84	34.15	1	6.00	11.00	

Selección de medidas de resumen

La elección de las medidas de resumen se realizó considerando la distribución y los valores atípicos de cada variable. Para semanas de desempleo se consideraron la media y desviación estándar, debido a que no presenta valores atípicos y su distribución es normal en la práctica. Para edad y años de trabajo anterior se consideraron la mediana y el rango intercuartílico debido a la presencia de valores atípicos y distribuciones no normales. En educación, aunque la distribución es normal en la práctica, la presencia de un valor atípico hace conveniente utilizar medidas resistentes a valores extremos.

Presentación de medidas resumen para datos categoricos

```
In [34]: for variable in cualitativas:
    print(f"\n{variable}")
    print(f"\nModa: {df[variable].mode()[0]}")
    print(f"\nFrecuencia absoluta: {df[variable].value_counts()}")
    print("\nFrecuencia relativa:")
    print(df[variable].value_counts(normalize=True))
    print("\nFrecuencia porcentual:")
```

```
print(df[variable].value_counts(normalize=True) * 100)
```

Casado

Moda: True

Frecuencia absoluta: Casado

True 35

False 15

Name: count, dtype: int64

Frecuencia relativa:

Casado

True 0.7

False 0.3

Name: proportion, dtype: float64

Frecuencia porcentual:

Casado

True 70.0

False 30.0

Name: proportion, dtype: float64

Cabeza Fam

Moda: True

Frecuencia absoluta: Cabeza Fam

True 34

False 16

Name: count, dtype: int64

Frecuencia relativa:

Cabeza Fam

True 0.68

False 0.32

Name: proportion, dtype: float64

Frecuencia porcentual:

Cabeza Fam

True 68.0

False 32.0

Name: proportion, dtype: float64

Administrador

Moda: False

Frecuencia absoluta: Administrador

False 45

True 5

Name: count, dtype: int64

Frecuencia relativa:

Administrador

False 0.9

True 0.1

Name: proportion, dtype: float64

```
Frecuencia porcentual:  
Administrador  
False    90.0  
True     10.0  
Name: proportion, dtype: float64
```

Ventas

Moda: False

```
Frecuencia absoluta: Ventas  
False    41  
True      9  
Name: count, dtype: int64
```

```
Frecuencia relativa:  
Ventas  
False    0.82  
True     0.18  
Name: proportion, dtype: float64
```

```
Frecuencia porcentual:  
Ventas  
False    82.0  
True     18.0  
Name: proportion, dtype: float64
```

Para las variables cualitativas se utilizaron la moda y las frecuencias absoluta, relativa y porcentual, debido a que permiten identificar tanto la categoría que se presenta con mayor frecuencia como la proporción que representa cada categoría dentro de la muestra.

Presentación de Histogramas y Box Plots para datos cuantitativos

```
In [35]: import matplotlib.pyplot as plt  
  
for variable in cuantitativas:  
  
    fig, ax = plt.subplots(figsize=(7, 4))  
  
    ax.hist(  
        df[variable].dropna(),  
        bins="auto",  
        edgecolor="black"  
    )  
  
    ax.axvline(  
        df[variable].mean(),  
        linestyle="--",  
        color="red",
```

```


        label=f"Media: {df[variable].mean():.2f}"
    )



    ax.axvline(
        df[variable].median(),
        linestyle=":",
        color="red",
        label=f"Mediana: {df[variable].median():.2f}"
    )


    ax.set_title(f"Distribución de {variable}")
    ax.set_xlabel(variable)
    ax.set_ylabel("Frecuencia")
    ax.legend()

plt.show()

```







```
In [36]: for variable in cuantitativas:

    fig, ax = plt.subplots(figsize=(7, 3))

    ax.boxplot(
        df[variable].dropna(),
        vert=False
    )

    ax.set_title(f"Diagrama de caja de {variable}")
    ax.set_xlabel(variable)

    plt.show()
```

Diagrama de caja de Semanas




Diagrama de caja de Edad






Diagrama de caja de Educación





```
In [37]: alpha = 0.05
for variable in cuantitativas:

    a2, p_value = normal_ad(df[variable].dropna())

    if p_value > alpha:
        conclusion = "No se rechaza la normalidad"
    else:
        conclusion = "Se rechaza la normalidad"

    print(f"Variable: {variable}")
    print(f"A²: {a2:.4f}")
    print(f"p-value: {p_value:.4f}")
    print(f"Conclusión: {conclusion}")
```

```
Variable: Semanas
A²: 0.3146
p-value: 0.5335
Conclusión: No se rechaza la normalidad
Variable: Edad
A²: 0.7577
p-value: 0.0455
Conclusión: Se rechaza la normalidad
Variable: Educación
A²: 0.4732
p-value: 0.2327
Conclusión: No se rechaza la normalidad
Variable: Años Trab Ant
A²: 1.5820
p-value: 0.0004
Conclusión: Se rechaza la normalidad
```

Análisis de resultados cuantitativos

Semanas de desempleo

Las semanas de desempleo presentan una media de **43.36 semanas** y una desviación estándar de **23.68 semanas**. No se identificaron valores atípicos y la distribución puede considerarse normal en la práctica. Mediante la regla empírica se determinó que aproximadamente el 95% de los valores se encuentra a dos desviaciones estándar de la media, en un intervalo de **-4.00 a 90.72 semanas**. Aunque el límite inferior es negativo, este no posee una interpretación práctica, ya que el número de semanas de desempleo no puede ser menor que cero.

Edad

La edad presenta una media de **34.60 años** y una mediana de **33 años**. Se identificaron valores atípicos superiores y la distribución no se considera normal. Por esta razón, la mediana y el rango intercuartílico permiten describirla sin verse tan afectados por los valores extremos. Mediante la desigualdad de Chebyshev se determinó que por lo menos el 75% de los valores se encuentra entre **16.48 y 52.72 años**.

Educación

La educación presenta una media de **13.52 años** y una mediana de **14 años**. Su distribución puede considerarse normal en la práctica, aunque presenta un valor atípico inferior. Debido a la presencia de este valor se consideró el rango intercuartílico como medida de variabilidad. De acuerdo con la regla empírica, aproximadamente el 95% de los valores se encuentra entre **8.14 y 18.90 años de educación**.

Años de trabajo anterior

Los años de trabajo anterior presentan una media de **8.36 años** y una mediana de **8 años**. La distribución presenta un sesgo hacia la derecha y varios valores atípicos superiores, por lo que no se considera normal. Mediante la desigualdad de Chebyshev se determinó que por lo menos el 75% de los valores se encuentra a dos desviaciones estándar de la media, entre **-3.33 y 20.05 años**. Aunque el límite inferior es negativo, este no posee una interpretación práctica, ya que el número de años de trabajo anterior no puede ser menor que cero.

Presentación de gráficas de barras para datos cualitativos

```
In [38]: for variable in cualitativas:
```

```

frecuencias = df[variable].value_counts(normalize=True) * 100

fig, ax = plt.subplots(figsize=(6, 4))


frecuencias.plot(
    kind="bar",
    edgecolor="black",
    ax=ax,
)
# add values on top of the bars
for i, v in enumerate(frecuencias):
    ax.text(i, v + 1, f"{v:.2f}%", ha='center', va='bottom')
ax.set_title(f"Distribución de Frecuencia porcentual de {variable}")
ax.set_ylim(0, max(frecuencias) + 10)

ax.set_xlabel(variable)


ax.set_ylabel("Frecuencia porcentual")

plt.show()


```




Distribución de Frecuencia porcentual de Cabeza Fam



Distribución de Frecuencia porcentual de Administrador





Análisis de variables cualitativas

En cuanto a las variables cualitativas, **35 de las 50 personas se encuentran casadas, representando el 70% de la muestra**, mientras que el 30% son solteras. Asimismo, **34 personas (68%) son cabeza de familia**, siendo esta la categoría más frecuente.

Respecto a las características laborales, solamente **5 personas (10%) son administradores**, mientras que el 90% no lo son. Finalmente, **9 personas (18%) trabajan en ventas**, mientras que el 82% restante no pertenece a esta área.

Conclusiones

El análisis permitió observar que las variables estudiadas presentan diferentes comportamientos, por lo que no es adecuado utilizar las mismas medidas estadísticas para todas ellas. Semanas de desempleo y educación presentan distribuciones normales en la práctica, mientras que edad y años de trabajo anterior presentan distribuciones no normales y valores atípicos. La presencia de estos valores hace importante considerar medidas resistentes, como la mediana y el rango intercuartílico, en lugar de depender únicamente de la media y la desviación estándar.

En las variables cualitativas se observa que la mayoría de las personas de la muestra están casadas y son cabeza de familia, mientras que una proporción considerablemente menor se desempeña como administrador o trabaja en ventas. En general, los resultados

muestran la importancia de considerar tanto la distribución como los valores atípicos y el tipo de variable antes de seleccionar las medidas utilizadas para describir un conjunto de datos.